

Input Content (IC)

Score: 1/5 — Serious concern | Confidence: high

Benchmark: MILU | Context: Bangladeshi Bengali University Student — Story Generation Thesis Deployment

Input Content definition: Whether individual datapoint content is culturally and contextually appropriate for the target region.

Each section below is followed by an evidence table. Three types of evidence are cited: [QN] — verbatim quotes extracted from the benchmark paper; [WEB-N] — web sources consulted during assessment; [DN] / [DATASET-DN] — sampled datapoints from the benchmark dataset, with an interpretation note.

Justification

All MILU content was scraped from Indian competitive exam portals [Q11, Q21, Q88], spanning national civil service, government/private organization, and Indian state-level exams [Q93, Q96, Q97, Q98]. No Bangladeshi exam sources are mentioned. Empirical inspection confirms 100% of sampled Bengali validation items are GPT-4O translations from English [DATASET-D8] (vs. documented 25% [Q43]), and every culturally-specific Bengali item references Indian institutions, persons, or geography [DATASET-D1 through D7]. Identical questions appear verbatim across all 11 language splits [DATASET-D7 cross-config], confirming Bengali content is parallel translation of pan-Indian English exam content rather than Bengali-medium regional sourcing. The deployment's required Bangladeshi register (Cholti with Arabic/Persian loanword density) is not represented; the sampled vocabulary uses Tatsama Sanskritic forms characteristic of pan-Indian written Bengali [DATASET-D1, D25].

ID	Evidence
Q11	"We create this benchmark by collecting questions from over 1500 competitive exams from India." (p.2)
Q21	"We gathered exam-specific questions by scraping various online exam portals that offer previously released question papers from various exams in multiple different languages." (p.3)
Q43	"Table 2 shows the overall statistics of MILU. Of the total 79K questions, only 25% of questions are translated from English, with the remainder" (p.4)
Q88	"All data described in this work was scraped from publicly available resources." (p.9)
Q93	"We collected our questions from over 40 exam types ranging from various National and state level civil service examinations to examinations conducted by various government and private organizations." (p.17)
Q96	"Table 6: Overview of various national-level exams and the corresponding years of coverage considered in MILU." (p.18)
Q97	"Table 7: Overview of various government and private organization exams and the corresponding years of coverage considered in MILU." (p.18)
Q98	"Table 8: Overview of various State-level civil services exams and the corresponding years of coverage considered in MILU." (p.18)
D1	১৯৯১ সালে আর্থিক সংকটের কারণ হিসেবে বৈদেশিক মুদ্রার রজি়ার্ড হ্রাসের তাৎক্ষণিক কারণ কী ছিল? ... তলে ও পট্টেরোলিয়াম পণ্যের আমদানির মূল্যেরে তীব্র বৃদ্ধি — India's 1991 balance-of-payments crisis question, translated from English (is_translated=True)
D7	বাহামানি সাম্রাজ্যের প্রথম রাজধানী কী ছিল? ... গুলবার্গা — Bahamani Kingdom capital — medieval Indian/Deccan history, not Bangladeshi
D8	All 21 Bengali examples show is_translated: True — Every Bengali validation example in sample is translated from English
D25	নচিরে বাক্যটির সঠিকি সক্রিয় রূপ নির্বাচন করুন। সবাই তার চমৎকার নৃত্য পরবিশেনা দ্বারা মুগ্ধ হয়েছিল। ... তার চমৎকার নৃত্য পরবিশেনা সবাইকে মুগ্ধ করেছিল। — Active voice conversion of Bengali sentence — grammar in written Bengali

Strengths

- STEM and universal academic content (chemistry, anatomy, computer science, mathematics) is culturally neutral and transfers validly to a Bangladeshi context [DATASET-D17, D18, D19, D20, D21], providing baseline signal on general academic Bengali competence.
- Bengali-language grammar and vocabulary items (antonyms, active/passive transformations) probe written Bengali competence directly [DATASET-D24, D25], offering some linguistic signal even if register-neutral.

ID	Evidence
D17	স্থারি প্রবাহ ট্রান্সফরমার _____ ধরনের। ... শলে — Constant current transformer type question — domain-neutral engineering/STEM
D18	নম্নলিখিত কোনগুলি অক্সিডেশন-রডিকেশন বিক্রিয়া? ... উপরে সবগুলি — Oxidation-reduction reactions — universal science content
D19	হৃদয়ে পেসমেকার দ্বারা চহিনতি হয়, ... এসএ নোড — SA node as cardiac pacemaker — universal medical content
D20	একটি অ্যাসেম্বলার যা একটি মেশিনে চলে কনিতু অন্য মেশিনে জন্ম মেশিনে কোড তরৈকিরে তাকে কবিলা হয়? ... ক্রস-অ্যাসেম্বলার — Cross-assembler definition — universal computer science
D21	দুটি পাত্র আছে X এবং Y। X-এ ১০০ মলি দুধ ... m = n — Milk-water mixture ratio problem — culturally neutral quantitative reasoning
D24	নচিরে প্রশ্নে, দেওয়া চারটি বিকল্পের মধ্যে থেকে সঠিে বিকল্পটি নিবিাচন করুন যা প্রদত্ত শব্দরে বপিরীত অর্থ প্রকাশ করে। ... শীতল — Antonym question in Bengali — vocabulary test
D25	নচিরে বাক্যটির সঠিক সক্রিয় রূপ নিবিাচন করুন। সবাই তার চমৎকার নৃত্য পরবিশেনা দ্বারা মুগ্ধ হয়েছিল। ... তার চমৎকার নৃত্য পরবিশেনা সবাইকে মুগ্ধ করেছিল। — Active voice conversion of Bengali sentence — grammar in written Bengali

Checklist

Checklist item definitions:

ID	Assessment Question
IC-1	Do inputs require region-specific cultural/geographic/dialectal knowledge?
IC-2	Does culturally sensitive content align with target culture?
IC-3	Flag inputs assuming Western-specific knowledge
IC-4	Regional annotator recruitment for culturally sensitive instances
IC-5	Document content issues harming content validity

Checklist responses:

IC-1: Yes — the deployment requires Bangladeshi-specific cultural, geographic, and dialectal knowledge (Q1, Q2, Q3 elicitation responses; [WEB-3, WEB-5, WEB-8]). Bangladeshi Cholti register with Arabic/Persian loanwords is required and is distinct from West Bengali norms.

IC-2: No — content reflects Indian national/state cultural framing exclusively [Q9, DATASET-D1 through D7]. The 1991 Indian financial crisis, Indian state elections, Indian constitutional law, Indian film awards, and Indian medieval/colonial monuments all populate the Bengali split.

IC-3: Yes — items requiring Indian-specific knowledge (Indian Election Commissioner removal procedure, AAP state politics, Indian Pharmacopoeia, India's National Food Security Mission) [DATASET-D3, D2, D14] do not transfer and may produce false negatives for users with Bangladeshi civic knowledge.

IC-4: No Bangladeshi annotators participated [Q8, Q86, Q87]; the documentation discloses only Indian institutional affiliation. The flagged_verification_priorities list confirms no Bangladeshi annotators are documented.

IC-5: Severe content-validity violation: Bengali content is (a) translated from English in 100% of sampled items [DATASET-D8], (b) culturally India-centric [DATASET-D2-D7], (c) lacks any Bangladeshi register markers [DATASET-D1, D25]. Strong scores on this content do not predict performance on Bangladesh-grounded story generation.

ID	Evidence
Q1	"MILU spans 8 domains and 41 subjects across 11 Indic languages, reflecting both general and culturally specific knowledge." (p.1)
Q2	"With an India-centric design, MILU incorporates material from regional and state-level examinations, covering topics such as local history, arts, festivals, and laws, alongside standard subjects like science." (p.1)
Q3	"We evaluate over 42 LLMs, and find that current LLMs struggle with MILU, with GPT-4o achieving the highest average accuracy at 74%." (p.1)
Q8	"Sshubam Verma ¹ Mohammed Safi Ur Rahman Khan ^{1,2} Vishwajeet Kumar ³ Rudra Murthy ³ Jaydeep Sen ³ Nilekani Centre at AI4Bharat 2Indian Institute of Technology, Madras 3IBM Research, India" (p.1)
Q9	"We designed MILU with an India-first perspective by collecting questions from various national, state, and regional exams." (p.2)

Q40	"For subjects with insufficient questions, we sampled questions from the English set from that subject and translated them into the required language using GPT-4O." (p.4)
Q43	"Table 2 shows the overall statistics of MILU. Of the total 79K questions, only 25% of questions are translated from English, with the remainder" (p.4)
Q86	"We would like to thank EkStep Foundation and Nilekani Philanthropies for their generous grant towards building datasets, models, tools and other resources for Indian languages." (p.9)
Q87	"We are also immensely grateful to the volunteers from the AI4Bharat team for their motivation and meticulous efforts in conducting manual audits." (p.9)
D1	১৯৯১ সালে আর্থিক সংকটের কারণ হিসেবে বদেশি মুদ্রার রজার্ভ হ্রাসের তাৎক্ষণিক কারণ কী ছিল? ... তলে ও পট্টেরোলিয়াম পণ্যের আমদানির মূল্যের তীব্র বৃদ্ধি — India's 1991 balance-of-payments crisis question, translated from English (is_translated=True)
D2	ফব্রুয়ারি- মার্চ ২০২২ এ অনুষ্ঠিত রাজ্য বধিানসভা নর্বিচাচনে, আম আদমপারটি (AAP) নমিনলখিতি কংন রাজ্যে সরকার গঠন করছেলি? ... পাঞ্জাব — Indian state assembly election (AAP in Punjab, 2022) — exclusively India-centric governance content
D3	নর্বিচাচন কমশিনারকে অপসারণ করা যতে পারে ... প্রধান নর্বিচাচন কমশিনারের সুপারশি রাষ্ট্রপতি — Removal of India's Election Commissioner — refers to Indian constitutional provisions
D4	'মঙ্গল ভারত' কাজটি নমিনলখিতি কংন জাতীয় নতোর দ্বারা রচতি হচ্ছেলি ... আচার্য বনিংবা ভাবে — "Mangal Bharat" — Indian national leader Vinoba Bhave; India-specific cultural/literary content
D5	৬৫তম ফলিমফয়ার অ্যাওয়ার্ডস, ২০২০-এ সেরা সনিমোটোগ্রাফরি জন্য পুরস্কারটিকে জতিছেনে? ... জয় ওজা — 65th Filmfare Awards (Indian film industry awards) — not Bangladeshi film industry
D6	_____ দলিলতিে কুতুব মনিারের নর্মাণ সম্পন্ন করছেলিনে ... ইলতুতমশি — Qutub Minar, Delhi — India-specific historical monument
D7	বাহমানি সাম্রাজ্যের প্রথম রাজধানী কী ছিলি? ... গুলবার্গা — Bahamani Kingdom capital — medieval Indian/Deccan history, not Bangladeshi
D8	All 21 Bengali examples show is_translated: True — Every Bengali validation example in sample is translated from English
D14	জাতীয় খাদ্য সুরক্ষা মশিন একটি ফসল উন্নয়ন প্রকল্প ... জাতীয় খাদ্য সুরক্ষা মশিন আগস্ট ২০০৭ সালে চালু হয়েলি — India's National Food Security Mission — Indian government program
D25	নচিরে বাক্যটির সঠিকি সক্রয়ি রূপ নর্বিচাচন করুন। সবাই তার চমৎকার নৃত্য পরবিশেনা দ্বারা মুগ্ধ হয়েলি। ... তার চমৎকার নৃত্য পরবিশেনা সবাইকে মুগ্ধ করেলি। — Active voice conversion of Bengali sentence — grammar in written Bengali
WEB-3	University student literacy supports text-based deployment (https://en.wikipedia.org/wiki/Education_in_Bangladesh)
WEB-5	July 2024 Uprising is a foundational live cultural reference for Bangladeshi students, post-benchmark (https://en.wikipedia.org/wiki/July_Revolution_(Bangladesh))
WEB-8	BengaliMoralBench's native Bangladeshi speaker consensus methodology is a model for the annotation approach this deployment requires (https://arxiv.org/abs/2511.03180)

Information Gaps

- Whether the test split (6,637 Bengali items) has a different translation rate or contains organically-sourced Bengali-medium items with West-Bengali-specific (but not Bangladeshi) cultural content
- Systematic register classification of Bengali items by a Bangladeshi linguist

Requires Expert Verification

- Native Bangladeshi linguistic audit of register markers across a larger Bengali sample
- Comparison of MILU Bengali content to BLUCK/BnMMLU Bangladeshi-sourced content for cultural-distance measurement

Remediation

Gap 1: 100% of sampled Bengali validation items are GPT-4O translations from English Indian-exam content [DATASET-D8]; no Bangladeshi register markers; no Bangladeshi named entities

Recommendation: Source supplementary content from Bangladesh-origin exams (BCS, SSC, HSC, university entrance) per BLUCK/BnMMLU methodology; for the thesis, document explicitly that MILU Bengali scores reflect translated pan-Indian content and report MILU only as a baseline-screening signal alongside Bangladesh-sourced benchmarks.

Gap 2: Bangladeshi Cholti register (Arabic/Persian loanword density) is absent from the sampled translated Bengali content [DATASET-D1, D25]; West-Bengali/pan-Indian Sanskrit register dominates

Recommendation: Supplement with the Bengali Dialectal Bias Benchmark [WEB-1] for explicit dialect coverage (including Barishal, Chittagong, Sylhet, Rangpur, Noakhali); commission a register-stratified sample of story-generation prompts that probes Bangladeshi Cholti vs. West-Bengali outputs.

ID	Evidence
D1	১৯৯১ সালে আর্থিক সংকটের কারণ হিসেবে বৈদেশী মুদ্রার রজিার্ড হ্রাসের তাৎক্ষণিক কারণ কী ছিল? ... তলে ও পট্রোলিয়াম পণ্যের আমদানির মূল্যের তীব্র বৃদ্ধি— India's 1991 balance-of-payments crisis question, translated from English (is_translated=True)
D8	All 21 Bengali examples show is_translated: True — Every Bengali validation example in sample is translated from English
D25	নচিরে বাক্যটির সঠিক সক্রিয় রূপ নির্বাচন করুন। সবাই তার চমৎকার নৃত্য পরবিশেনা দ্বারা মুগ্ধ হয়েছিল। ... তার চমৎকার নৃত্য পরবিশেনা সবাইকে মুগ্ধ করেছিল। — Active voice conversion of Bengali sentence — grammar in written Bengali
WEB-1	https://arxiv.org/abs/2603.21359